



Projet TER

Interprétabilité des modèles linéaires et non linéaires
Méthodes locales et globales

Imen Miloudi & Warda Saikouk

————— Encadré par Pierre Pudlo —————

Master 1 MAS DS
Année universitaire 2025-2026

Remerciements

Nous tenons à remercier notre encadrant, Monsieur Pierre Pudlo, pour sa disponibilité, sa pédagogie et ses précieux conseils tout au long de ce Travail d'Étude et de Recherche.

Son expertise et ses orientations nous ont guidées avec bienveillance dans la découverte du domaine exigeant et passionnant de l'explicabilité de l'intelligence artificielle (XAI).

Enfin, nous remercions l'ensemble de l'équipe pédagogique du Master 1 MAS DS de l'Université d'Aix-Marseille pour la qualité de la formation qui nous a permis de mener à bien ce projet.

Déclaration d'utilisation d'outils d'Intelligence Artificielle

Dans le cadre de ce projet, des outils d'IA ont été utilisés pour nous assister dans notre travail. Plus précisément, ces outils ont aidé à la génération de certaines structures de code Python, au paramétrage des bibliothèques d'explicabilité (`lime`), ainsi qu'à l'amélioration orthographique et grammaticale de certaines portions du document LaTeX.

Nous certifions que l'ensemble des concepts théoriques, la conception des expérimentations, l'analyse critique des résultats et la rédaction finale sont exclusivement issus de notre travail et de notre réflexion.

Table des matières

Remerciements	1
Déclaration d'utilisation d'outils d'IA	1
Introduction	4
I Bases Théoriques de l'Explicabilité	5
I.1 LIME : Local Interpretable Model-agnostic Explanations	5
a) Agnosticisme et Interprétabilité : Local vs Global	5
b) Fonctionnement Algorithmique	5
c) Formulation Mathématique	6
d) Limites Théoriques de l'Approche	6
I.2 SHAP : SHapley Additive exPlanations et Théorie des Jeux	8
a) Additive Feature Attribution methods et théorie des jeux coopératifs . . .	8
b) Les valeurs de Shapley : Une répartition équitable	8
c) Propriétés fondamentales	9
I.3 KernelSHAP : L'approximation agnostique	10
I.4 TreeSHAP : Algorithme spécialisé pour les modèles à base d'arbres	11
a) Avantages de la spécialisation	11
II Expérimentations et Mise en œuvre Pratique	12
II.1 Expérimentations avec LIME	12
a) Le cas du Titanic : Un « cas d'école » pour l'explicabilité	12
b) Enjeux éthiques et limites techniques : Le cas COMPAS	14
c) Application au diagnostic médical : Breast Cancer	15
II.2 Limites de LIME	16
a) Instabilité	16
b) Sensibilité au voisinage (Kernel Width)	16
II.3 Expérimentations avec SHAP	16
a) Le cas du Titanic	17
b) Le cas COMPAS	17
c) Application au diagnostic médical : Breast Cancer	17
II.4 Synthèse des observations expérimentales	18
III LIME vs SHAP	19
III.1 Stabilité et Robustesse	19
a) La fragilité de LIME	19
b) Le déterminisme de SHAP	19
III.2 Propriétés des méthodes	19
III.3 Du Local au Global	20
a) LIME : Une vision strictement locale	20
b) SHAP : L'unification Local-Global	20

III.4 Compromis entre les deux méthodes	20
Conclusion Générale	22
A Annexes : Figures et Illustrations	24
B Fonctionnement des modèles "Boîtes Noires"	33
B.1 Les Arbres CART et les Random Forest	33
B.2 XGBoost (Extreme Gradient Boosting)	34

Introduction

Au cours de la dernière décennie, l'apprentissage automatique (Machine Learning) a connu un essor sans précédent, s'imposant comme un levier de décision majeur dans de nombreux secteurs d'activité. Cependant, l'augmentation constante des performances prédictives s'est accompagnée d'une complexification croissante des modèles. Les algorithmes les plus performants, tels que les Random Forest, le Gradient Boosting ou les réseaux de neurones, sont souvent qualifiés de « boîtes noires ». Bien qu'ils capturent efficacement des relations non linéaires complexes, leur structure interne demeure opaque, ce qui rend presque impossible la compréhension directe des raisons menant à une prédiction spécifique.

Cette opacité soulève des enjeux critiques, particulièrement dans des domaines où les conséquences d'une décision automatisée sont lourdes. Qu'il s'agisse de diagnostics médicaux ou de décisions au sein du système judiciaire, la seule performance statistique ne suffit plus. Il devient impératif de garantir la transparence, l'équité et la robustesse des modèles afin que les utilisateurs finaux puissent accorder leur confiance aux outils algorithmiques. C'est dans ce cadre que s'inscrit l'Explicabilité de l'Intelligence Artificielle (XAI), un champ de recherche visant à rendre les décisions des modèles complexes compréhensibles pour l'humain.

L'enjeu central de notre Travail d'Étude et de Recherche est d'évaluer les outils permettant d'expliquer ces mécanismes opaques. Dès lors, la problématique de notre travail peut se formuler ainsi : **Dans quelle mesure les méthodes d'explicabilité, telles que LIME et SHAP, influencent-elles la fiabilité et la stabilité des informations fournies par ces modèles boîtes noires ? Et comment ces méthodes se comparent-elles ?** Il s'agira notamment d'étudier si ces explications sont mathématiquement cohérentes et si elles s'avèrent robustes face aux variations inhérentes à leur algorithme, en particulier lors de l'échantillonnage des données ou du paramétrage du voisinage local.

Pour répondre à cette problématique, ce rapport est structuré en trois parties principales. Dans un premier temps, nous poserons les bases théoriques en présentant les principes de l'explicabilité locale. Nous détaillerons le fonctionnement de l'algorithme LIME (*Local Interpretable Model-agnostic Explanations*), basé sur l'approximation par des modèles de substitution, ainsi que l'approche SHAP, ancrée dans la théorie des jeux.

Dans un deuxième temps, nous confronterons ces théories à la pratique à travers l'étude de trois cas d'usage distincts. Nous débuterons par l'analyse du jeu de données *Titanic*, un standard de l'apprentissage automatique dont les variables facilement compréhensibles offrent une première approche visuelle et intuitive des algorithmes d'explicabilité. Nous déploierons ensuite ces méthodes sur des jeux de données soulevant des enjeux éthiques et métiers plus complexes : le diagnostic médical à travers la prédiction de tumeurs malignes (jeu de données *Breast Cancer*) et l'évaluation du risque de récurrence au sein du système judiciaire (jeu de données *COMPAS*). Cela nous permettra aussi d'étudier limites pratiques de ces méthodes.

Enfin, nous consacrerons une partie critique à la comparaison des performances de ces deux méthodes. Une attention particulière sera portée à la question de l'instabilité des explications générées, en illustrant comment des variations dans l'échantillonnage ou la définition du voisinage peuvent influencer, voire biaiser, l'interprétation finale des résultats.

Bases Théoriques de l'Explicabilité

Dans le cadre de nos expérimentations, nous nous sommes concentrées sur des algorithmes ensemblistes réputés pour leurs hautes performances prédictives, mais souffrant d'une forte opacité : les forêts aléatoires (*Random Forest*) et l'amplification de gradient (*XGBoost*). Afin d'alléger le corps de ce rapport centré sur l'explicabilité, les fondements mathématiques relatifs à *Random Forest* et au *XGBoost* sont détaillés en Annexe B.

Ces modèles d'apprentissages, ainsi que les réseaux de neurones, offrent des performances de prédiction exceptionnelles. Cependant, leur architecture mathématique complexe en fait de véritables « boîtes noires ». L'enjeu de la Data Science explicable est de fournir des méthodes permettant de comprendre comment et pourquoi un modèle produit une prédiction donnée.

Dans cette première partie, nous poserons les bases théoriques en nous appuyant sur la littérature scientifique pour détailler deux approches majeures de l'explicabilité : LIME et SHAP.

I.1 LIME : Local Interpretable Model-agnostic Explanations

Proposée en 2016 par Ribeiro *et al.* [RSG16], la méthode LIME construit un modèle de substitution local autour de chaque prédiction afin d'en expliquer le comportement de manière simplifiée.

a) *Agnosticisme et Interprétabilité : Local vs Global*

Pour appréhender LIME, il est important de distinguer deux niveaux d'analyse :

- **L'interprétabilité globale** : Elle cherche à expliquer le fonctionnement général du modèle prédictif sur l'ensemble du jeu de données.
- **L'interprétabilité locale** : Elle se concentre sur une instance unique, avec pour objectif de comprendre précisément pourquoi le modèle a pris une décision spécifique pour cette observation précise. LIME s'inscrit exclusivement dans cette approche locale en fournissant des explications sur chaque valeur, et non de manière globale.

Par ailleurs, LIME se définit comme une méthode « agnostique » (Model-agnostic). Cela signifie qu'elle est utilisable sur tout type de modèle de Machine Learning. LIME observe uniquement la relation entre les entrées et les sorties du modèle, ce qui lui permet d'expliquer aussi bien le comportement de forêts aléatoires que celui de réseaux de neurones profonds.

b) *Fonctionnement Algorithmique*

L'intuition de LIME repose sur l'approximation de n'importe quel classifieur ou régresseur par un modèle simple et intrinsèquement interprétable (généralement linéaire), et ce, localement autour d'une prédiction spécifique. Le fonctionnement de l'algorithme se décompose en quatre étapes fondamentales :

1. **Échantillonnage** : LIME génère un nouveau jeu de données artificiel en perturbant l'instance initiale x . La nature de cette perturbation dépend du type de données : pour du texte, des mots sont supprimés aléatoirement ; pour une image, des zones sont grisées de façon aléatoire ; et pour des données tabulaires, du bruit statistique est ajouté.
2. **Prédiction** : L'algorithme fait ensuite passer ces nouvelles instances perturbées, notées z , dans le modèle original (la boîte noire, notée f) afin d'obtenir leurs prédictions respectives.
3. **Pondération** : Une distance est calculée entre l'observation originale x et l'instance perturbée z . Plus l'instance perturbée est proche de l'originale, plus le poids qui lui est attribué, noté $\pi_x(z)$, est important.
4. **Modèle de substitution (Surrogate model) et Explication** : LIME entraîne un modèle simple (comme une régression linéaire) sur ces données perturbées, en intégrant les poids précédemment calculés. L'objectif est que ce modèle imite le comportement de f localement. Les poids de ce modèle de substitution deviennent alors l'explication finale : un poids positif indique une contribution en faveur de la classe prédite, tandis qu'un poids négatif indique une contribution contraire.

c) *Formulation Mathématique*

D'un point de vue formel, la recherche de cette explication mathématique se traduit par la résolution d'un problème d'optimisation. LIME cherche le meilleur modèle d'explication g (par exemple, une régression linéaire) appartenant à une classe de modèles interprétables G , en minimisant l'équation suivante :

$$\xi(x) = \arg \min_{g \in G} \mathcal{L}(f, g, \pi_x) + \Omega(g)$$

Cette formulation mathématique traduit l'équilibre recherché par la méthode :

- La **fonction de perte** $\mathcal{L}(f, g, \pi_x)$ mesure l'écart d'approximation. Elle évalue à quel point le modèle de substitution g se trompe par rapport aux prédictions de la boîte noire f sur le voisinage défini par les poids π_x . L'objectif est de minimiser cette erreur de fidélité locale.
- Le **terme de régularisation** $\Omega(g)$ agit comme une pénalité de complexité. Il force le modèle g à rester parcimonieux (par exemple en limitant le nombre de variables utilisées via une régularisation de type Lasso), condition indispensable pour garantir une explication humainement lisible.

d) *Limites Théoriques de l'Approche*

Si l'optimisation proposée par LIME est intéressante, elle repose sur des hypothèses mathématiques fortes qui constituent des limites théoriques :

- **L'hypothèse de linéarité stricte** : L'algorithme postule qu'à une échelle suffisamment petite, toute frontière de décision complexe peut être approximée par un hyperplan linéaire. Or, si la fonction de la boîte noire f est extrêmement non linéaire, même dans un voisinage très restreint, le modèle de substitution g sera « pauvre » et son score d'ajustement (R^2) sera très faible. L'explication générée perdra alors toute sa fidélité.
- **L'arbitraire du voisinage** : La définition mathématique de ce qui est « proche » ou « lointain » repose entièrement sur la fonction de pondération π_x et son hyperparamètre de largeur de noyau (*kernel width*). D'un point de vue théorique, il n'existe pas de méthode universelle pour optimiser ce paramètre, laissant ce choix à l'utilisateur, nous verrons plus tard que c'est un choix assez compliqué. En effet, si LIME est assez simple à comprendre d'un point de vue mathématiques, la partie théorique sera plus compliquée, les nombreux paramètres apportent une difficulté.

- **Échantillons hors distribution** : Lors de la phase de perturbation, LIME génère des données artificielles en modifiant les variables de manière indépendante. Cette approche naïve ignore les corrélations réelles entre les caractéristiques. LIME peut ainsi soumettre à la boîte noire des échantillons virtuellement impossibles (par exemple, un profil combinant un âge de 5 ans avec un salaire de 100 000 euros). Le modèle f est alors contraint d'extrapoler sur un domaine de définition qu'il n'a jamais rencontré lors de son apprentissage, ce qui fausse l'explication locale.

Nous pourrions observer ces limites dans la partie pratique.

Bien qu'intéressante mathématiquement, cette optimisation locale a quelques défauts, notamment en termes de stabilité face à l'échantillonnage aléatoire, des limites que nous explorerons dans la dernière partie de ce rapport.

Si LIME aborde l'explicabilité par la construction d'un modèle de substitution, une autre approche propose de résoudre ce problème sous un angle radicalement différent : celui de la théorie des jeux.

I.2 SHAP : SHapley Additive exPlanations et Théorie des Jeux

Nous allons présenter ici une autre méthode d'explication nommée Shapley Additive explanations (SHAP).

Introduite en 2017 par Scott M. Lundberg et Su-In Lee dans l'article "*A Unified Approach to Interpreting Model Predictions*" ([LL17]), la méthode SHAP s'est imposée comme un standard de l'interprétabilité. Contrairement à LIME qui repose sur une intuition assez simpliste, SHAP s'appuie sur une base mathématique rigoureuse : la théorie des jeux coopératifs.

Comme pour la méthode LIME, SHAP ne fait pas d'hypothèses sur le modèle étudié, c'est donc aussi une méthode agnostique (Model-agnostic).

Dans cette partie nous ré-utilisons les notions de modèles de substitution et introduisons les variables d'entrée simplifiées (simplified inputs) qui permettent de représenter de manière concise les données originales.

a) *Additive Feature Attribution methods et théorie des jeux coopératifs*

Plusieurs méthodes d'explication appartiennent à la classe de méthodes *additive feature attribution methods*.

On note f le modèle étudié qui prend en paramètre $z \in \mathbb{R}^M$ où M est le nombre de variables d'entrées du modèle. On cherche à interpréter f comme un jeu collaboratif entre les M variables. Pour cela on introduit ce qu'on appelle des entrées simplifiées $z' \in \{0, 1\}^M$ définies telles que si $z'_i = 1$ avec $i \in \{1, \dots, M\}$ alors la i -ème variable est prise en compte, et dans le cas où $z'_i = 0$ elle ne l'est pas.

Soient $z \in \mathbb{R}^M$, et $z' \in \{0, 1\}^M$ on définit alors $\hat{f}$ comme suit :

$$\hat{f}(z, z') = \phi_0 + \sum_{i=1}^M \phi_i(z) z'_i \quad (\text{I.1})$$

où $\phi_0 = \mathbb{E}(\hat{f}(z, 0_{\mathbb{R}^M}))$ est la valeur prédite moyenne du modèle.

L'objectif est de trouver les coefficients $\phi_i(z) \in \mathbb{R}$ qui représentent au mieux la contribution de chaque variable à la prédiction finale.

Ces méthodes définissent donc un modèle d'explication $\hat{f}$ du modèle f comme une fonction linéaire de l'entrée simplifiée z' .

Cette classe de méthodes est intéressante car plusieurs méthodes populaires en font partie dont : LIME, DeepLift qui sert à expliquer les modèles de Deep Learning et plus particulièrement les valeurs de Shapley.

b) *Les valeurs de Shapley : Une répartition équitable*

Définition intuitive

Avec les valeurs de Shapley, on cherche à expliquer comment les variables influent le résultat du modèle f par exemple sur une seule prédiction

Ainsi dans la figure A.1 de l'annexe on part de la valeur prédite moyenne $\mathbb{E}[f(z)]$ et à partir de cette dernière, on ajoute les coefficients ϕ_i , qui sont les valeurs de Shapley, pour finalement arriver à la valeur qui nous intéresse $f(z)$.

Dans l'exemple de l'image, $\mathbb{E}[f(z)] = 1.904$ et il représente la valeur moyenne d'une maison, les coefficients ϕ_i permettent de retrouver la prédiction $f(z) = 1.681$. On peut ainsi voir facilement que la valeur d'une maison est expliquée en grande partie par sa position géographique (Longitude, Latitude), ce qui peut être dû par exemple au fait que la maison est à côté d'une

plage, ou au centre ville. Les valeurs de Shapley expliquent comment les variables influent sur la prédiction mais ne donnent pas nécessairement les raisons du phénomène.

Le concept central des valeurs de Shapley est d'attribuer à chaque variable une valeur correspondant à sa contribution moyenne à la prédiction, en considérant toutes les combinaisons possibles de variables et en comparant les résultats du modèle selon s'il a été entraîné avec ou sans la variable.

Définition formelle

En notant :

- f le modèle étudié
 - $x \in \mathbb{R}^M$ l'entrée originale (qui contient les valeurs des variables)
 - i l'indice de la variable qui nous intéresse.
 - F l'ensemble de toutes les variables.
 - les ensembles S des sous-ensembles de F ne contenant pas la i -ème variable.
 - f_S les modèles issus de f qui prennent uniquement en paramètre les variables contenues dans l'ensemble S
 - x_S les entrées issues de x contenues dans S
- Pour une instance x , la valeur de Shapley ϕ_i de la i -ème variable est définie par :

$$\phi_i = \sum_{S \subseteq F \setminus i} \frac{|S|!(|F| - |S| - 1)!}{|F|!} (f_{S \cup i}(x_{S \cup i}) - f_S(x_S)) \quad (I.2)$$

Dans l'écart $(f_{S \cup i}(x_{S \cup i}) - f_S(x_S))$ les termes en f_E représentent les modèles qui ont été entraînés avec les variables contenues dans l'ensemble E . On mesure donc l'impact sur le résultat du modèle en ajoutant la variable i .

La valeur de Shapley est donc la moyenne pondérée de ces contributions marginales sur toutes les coalitions possibles.

c) Propriétés fondamentales

En plus d'appartenir aux additive feature methods, les valeurs de Shapley sont les seules à vérifier les trois propriétés importantes suivantes :

On note x' l'entrée simplifiée de x

1. **Local Accuracy** : Le modèle de substitution g doit correspondre au modèle original f au moins pour les entrées simplifiées :

$$f(x) = \hat{f}(x, x') = \phi_0 + \sum_{i=1}^M \phi_i(x) x'_i$$

2. **Missingness** : Si une variable est absente de l'entrée simplifiée, alors sa contribution doit être nulle :

$$x'_i = 0 \implies \phi_i = 0$$

3. **Consistency** : Si un modèle change de telle sorte que la contribution marginale d'une variable augmente (ou reste égale), alors sa valeur de Shapley ne peut pas diminuer. Cette propriété assure la robustesse de l'explication.

Formellement, en notant $f_x(z') = f(h_x(z'))$, où h_x est la fonction qui permet de passer de l'entrée simplifiée $z' \in \{0, 1\}^M$ à la valeur originale $x \in \mathbb{R}^M$. Et $z' \setminus i$ pour dire $z'_i = 0$. Alors pour tous modèles f et f' , si

$$f'_x(z') - f'_x(z' \setminus i) \geq f_x(z') - f_x(z' \setminus i)$$

pour tout $z' \in 0, 1^M$, où M est le nombre total de variables. Alors :

$$\phi_i(f', x) \geq \phi_i(f, x)$$

où $\phi_i(f, x)$ est la valeur ϕ_i pour le modèle f et l'entrée x .

Ce sont ces propriétés qui garantissent la justesse des explications fournies par les valeurs de Shapley, comme celle de la figure A.1 dans l'annexe.

I.3 KernelSHAP : L'approximation agnostique

Le calcul exact des valeurs de Shapley est coûteux voire impossible à réaliser car il y a 2^M combinaisons en tout. Pour cela des méthodes servant à estimer ces valeurs ont été développées, en particulier les algorithmes SHAP.

Le premier est *KernelSHAP* qui propose une méthode d'estimation efficace en combinant l'intuition de LIME et la rigueur de Shapley.

On commence par définir les paramètres :

1. les poids sont $\pi_{x'}(z') = \frac{M-1}{\binom{M}{|z'|} |z'| (M-|z'|)}$ où z' est une entrée simplifiée.
2. on définit la fonction h_x telle que $f(h_x(x')) = E(f(x)|x_S)$, c'est elle qui permet de passer des entrées simplifiées $x' \in \{0, 1\}^M$ aux données originales $x \in \mathbb{R}^M$, de plus elle est spécifique à x .
3. La fonction de perte est $L(f, \hat{f}, \pi_{x'}) = \sum_{z' \in Z} [f(h_x(z')) - \hat{f}(x, z')]^2 \pi_{x'}(z')$ où $x \in \mathbb{R}^M$ est la valeur pour laquelle on cherche à trouver les valeurs de Shapley et Z est l'ensemble des entrées simplifiées.
4. $|z'|$ représente le nombre de composantes non nulles dans z' .
5. Le terme de régularisation $\Omega(\hat{f}) = 0$, on cherche donc le résultat le plus proche de f .

Les étapes de l'algorithme sont :

1. On commence par créer les entrées simplifiées z' à partir des données originales z , où les z'_i marquent la présence ou l'absence de la i -ème variable.
2. On obtient les prédictions en appliquant la fonction f aux $h_x(z')$.
3. On calcule les poids $\pi_{x'}(z')$ pour tous les z' .
4. On entraîne le modèle $\hat{f}$ en choisissant comme fonction de perte L .

À la fin de l'algorithme on récupère les estimations des valeurs de Shapley, qu'on a notées ici ϕ_i . À l'étape de l'entraînement du modèle $\hat{f}$ qui est défini comme dans l'équation (1.2) dans la partie a), la linéarité de ce dernier joue un rôle important. En effet, c'est ce qui permet d'appliquer la régression linéaire pour résoudre le problème suivant :

$$\xi = \arg \min_{\hat{f} \in \mathcal{G}} L(f, \hat{f}, \pi_{x'}) + \Omega(g)$$

Dans l'expression de la fonction de perte, on retrouve l'écart entre le modèle original f et son modèle de substitution $\hat{f}$. Comme on cherche à minimiser L , on comprend que c'est cette différence qui permet d'obtenir un modèle $\hat{f}$ et donc des ϕ_i qui expliquent bien f .

En dehors du fait que cette méthode est assez lente pour donner une approximation des valeurs de Shapley, cette méthode présente d'autres inconvénients. On estime $f(h_x(z'))$ par $\mathbb{E}_{\bar{S}}(f(z))$, où $\bar{S}$ est l'ensemble des variables qui ne sont pas dans S , c'est à dire qu'on échantillonne suivant la distribution marginale, en supposant que les variables sont indépendantes. Ceci a pour effet que certains liens entre les variables ne sont pas bien pris en compte. On peut donc se retrouver avec des valeurs de Shapley qui ne sont pas nulles alors que la variable n'a pas de contribution.

Pour résoudre ces problèmes d'autres versions de KernelSHAP on été proposées, comme par exemple en 2021 dans l'article "Explaining Individual Predictions When Features Are Dependent : More Accurate Approximations to Shapley Values." par Aas, Kjersti, Martin Jullum, et Anders Løland.

I.4 TreeSHAP : Algorithme spécialisé pour les modèles à base d'arbres

Pour nos expérimentations sur la *Random Forest* et le *XGBoost*, nous avons privilégié la fonction **TreeExplainer** de la bibliothèque **shap**. Contrairement à **KernelSHAP**, qui est une méthode agnostique, **TreeSHAP** utilise des algorithmes conçus spécifiquement pour les structures d'arbres de décision, ce qui le rend plus performant et plus précis.

a) *Avantages de la spécialisation*

Les modèles basés sur les arbres sont très populaires dans de nombreux domaines, comme le diagnostic médical, en raison de leur capacité à capturer des relations non linéaires complexes. L'utilisation d'algorithmes spécialisés comme TreeSHAP présente deux avantages majeurs :

- **Efficacité computationnelle** : Là où KernelSHAP nécessite un temps de calcul exponentiel par rapport au nombre de variables, TreeSHAP réduit cette complexité à un temps polynomial ($O(TLD^2)$), permettant des calculs quasi instantanés sur des modèles complexes.
- **Exactitude des résultats** : TreeSHAP ne se contente pas d'une approximation par échantillonnage ; il fournit les valeurs de Shapley exactes en exploitant la structure interne du modèle.

Il existe plusieurs algorithmes Tree SHAP, et celui que nous allons présenter n'est ni celui qui est actuellement implémenté dans TreeExplainer, ni celui qui est le plus rapide.

Cet algorithme présenté dans ([LEC⁺19]) repose sur une procédure récursive qui parcourt l'arbre pour trouver $\mathbb{E}(f(x)|x_S)$. Le principe intuitif suit le chemin de décision (Figure A.2) :

1. **Nœud feuille** : Si l'algorithme atteint une feuille, il retourne la valeur de prédiction stockée dans celle-ci.
2. **Nœud de division (Split)** : Si le nœud actuel effectue une division sur une variable i :
 - **Si la variable i fait partie de l'ensemble S** (variables observées) : On suit uniquement la branche correspondant à la valeur réelle de l'instance x .
 - **Si la variable i n'est pas dans S** : On parcourt récursivement les deux branches. Le résultat final pour ce nœud est la moyenne pondérée des résultats des deux branches enfants, calculée en fonction du nombre d'individus de l'échantillon d'entraînement ayant pris chaque chemin.

Définition des termes techniques

Pour comprendre la Figure A.2, il est nécessaire de définir les paramètres utilisés dans l'implémentation de Lundberg :

- v : Valeurs de prédiction (ou sorties) associées aux feuilles de l'arbre.
- a et b : Les vecteurs d'indices des nœuds enfants (respectivement gauche et droite).
- t : Les seuils de division (thresholds) utilisés à chaque nœud pour séparer les données.
- d : L'index de la variable (feature) utilisée pour la division à un nœud spécifique.
- w : Les poids représentant le nombre d'exemples d'entraînement ayant traversé chaque nœud.

Expérimentations et Mise en œuvre Pratique

L'objectif de cette seconde partie est de confronter les bases théoriques de l'explicabilité locale, détaillées précédemment, aux réalités de données concrètes. À travers trois jeux de données distincts, nous allons évaluer la capacité des algorithmes LIME et SHAP à fournir des informations fiables, stables et intelligibles sur les décisions de nos modèles « boîtes noires ».

II.1 Expérimentations avec LIME

a) Le cas du Titanic : Un « cas d'école » pour l'explicabilité

Pour débiter notre analyse pratique, nous avons choisi le jeu de données du *Titanic*. Ce dataset standard de l'apprentissage automatique est idéal pour servir de tutoriel à l'utilisation de LIME. En effet, les variables telles que le sexe, l'âge ou la classe sociale sont extrêmement intuitives et correspondent à des connaissances historiques partagées, notamment le protocole de sauvetage « les femmes et les enfants d'abord ».

Cette approche visuelle nous permettra de valider que notre modèle de forêt aléatoire a correctement capturé les dynamiques de survie avant d'aborder des problématiques éthiques plus complexes.

Analyse d'une explication locale individuelle :

Le fonctionnement de LIME repose sur l'approximation locale du modèle complexe autour d'une instance spécifique. Pour illustrer cela, nous avons sélectionné un passager du jeu de test dont la probabilité de survie est estimée à seulement 12% par notre modèle Random Forest.

L'observation de la **Figure A.3** permet de décomposer immédiatement la décision du modèle :

- **Le Sexe** ($0.00 < Sex \leq 1.00$) : Le fait d'être un homme est le facteur le plus pénalisant (barre rouge la plus significative), ce qui est cohérent avec les priorités de sauvetage historiques.
- **La Classe** ($2.00 < Pclass \leq 3.00$) : L'appartenance à la troisième classe agit comme le second facteur négatif majeur identifié par le modèle de substitution.
- **L'Âge** ($22.00 < Age \leq 28.00$) : À l'inverse, l'âge de ce passager semble être un facteur légèrement positif (en vert), bien que son impact soit marginal par rapport au genre et à la classe.

Conformément à la formulation mathématique de LIME, les variables continues ont été discrétisées pour garantir une meilleure lisibilité humaine de l'explication. Ici, l'analyse locale nous apprend que pour ce passager précis, son genre masculin et son statut social précaire sont les raisons fondamentales de sa non-survie prédite par l'algorithme.

Graphes d'interactions : Matrice de corrélation Valeurs-Poids

Bien que LIME soit une méthode intrinsèquement locale, il est possible de tester la cohérence globale du modèle en agrégeant les explications sur l'ensemble du jeu de test. Pour ce faire, nous avons généré une carte de chaleur (Figure A.4) représentant la corrélation entre les caractéristiques réelles des passagers et les poids locaux attribués par LIME pour la classe « Survivant ».

L'analyse de cette matrice permet de valider la structure décisionnelle de la forêt aléatoire à deux niveaux :

1. **Validation de la logique métier (Diagonale)** : On observe une corrélation négative parfaite entre la variable *Sex* et son poids associé (-1.00). Plus la valeur du sexe augmente (passage de Femme=0 à Homme=1), plus le poids LIME diminue, pénalisant la probabilité de survie. Il en va de même pour la *Pclass* (-0.91), confirmant que le modèle a correctement intégré la règle historique selon laquelle l'appartenance aux classes sociales inférieures diminuait drastiquement les chances de sauvetage.
2. **Hors-diagonale** : L'intérêt majeur de cette visualisation réside dans les corrélations croisées. Notamment, la corrélation positive entre *Fare* (prix du billet) et le poids de la *Pclass* (0.48) suggère que le modèle ne traite pas ces variables de manière isolée. L'impact positif de la première classe est renforcé par un prix de billet élevé, révélant une synergie captée par l'algorithme. À l'inverse, la forte corrélation négative entre *Pclass* et le poids du *Fare* (-0.70) indique que pour les passagers de troisième classe, l'avantage lié au prix du billet disparaît presque totalement dans la logique du modèle.

Cette heatmap transforme LIME d'un simple outil de diagnostic individuel en un instrument d'audit global, permettant de s'assurer que la « boîte noire » n'utilise pas de relations aberrantes ou statistiquement fragiles pour produire ses prédictions.

Analyse des interactions : Influence du genre sur l'impact de la classe

Pour clore cette étude du cas Titanic, nous analysons comment l'importance accordée à une variable peut varier en fonction de la valeur d'une autre. La Figure A.5 illustre cette dynamique en affichant le poids local attribué à la classe sociale (*Pclass*) en fonction du sexe du passager.

L'analyse de ce graphique d'interaction révèle plusieurs comportements clés de la forêt aléatoire :

- **L'effet de seuil de la 3ème classe** : On observe une rupture nette au niveau de la classe 3. Alors que pour les classes 1 et 2, les poids LIME sont majoritairement positifs (favorisant la survie), ils s'effondrent systématiquement sous la barre du zéro pour la classe 3. Cela confirme que l'appartenance à la classe « pauvre » est un prédicteur de décès quasi-systématique pour le modèle.
- **La modulation par le sexe** : L'aspect le plus intéressant réside dans la dispersion des points au sein d'une même classe. En classe 3, on remarque que les points bleus (femmes) atteignent des poids négatifs plus extrêmes (jusqu'à -0.15) que les points rouges (hommes).
- **Capture de la non-linéarité** : Ce graphe prouve visuellement que LIME parvient à extraire des relations non-linéaires. Le modèle « sur-pénalise » la troisième classe spécifiquement lorsqu'il s'agit d'hommes. À l'inverse, en première classe, le genre semble avoir moins d'influence sur le poids de la classe, les points étant plus resserrés vers le haut.

En conclusion de ce premier cas pratique, l'utilisation de LIME sur le Titanic démontre que l'explicabilité locale, lorsqu'elle est agrégée, permet de valider non seulement les tendances globales du modèle, mais aussi sa capacité à reproduire des logiques d'interactions complexes conformes à la réalité historique du naufrage.

b) *Enjeux éthiques et limites techniques : Le cas COMPAS*

Après avoir validé la mécanique de LIME sur un cas simple, nous appliquons la méthode au jeu de données *COMPAS* (Correctional Offender Management Profiling for Alternative Sanctions). Ce jeu de données, utilisé par la justice américaine pour évaluer les risques de récidive, est au cœur d'une controverse majeure concernant les biais raciaux algorithmiques.

Analyse d'une explication locale : les déterminants de la récidive

L'objectif est ici de comprendre comment notre modèle *Random Forest* justifie une prédiction de risque élevé. La Figure A.6 présente l'explication locale pour un individu dont la probabilité de récidive est estimée à 64%.

L'analyse des poids locaux révèle une hiérarchie claire des facteurs d'influence :

- **Le passé judiciaire** ($2.00 < \text{priors_count} \leq 5.00$) : C'est le contributeur principal à la prédiction. Le modèle considère qu'un historique criminel modéré est le signe le plus fort d'une récidive future.
- **L'absence d'antécédents juvéniles** ($\text{juv_fel_count} \leq 0.00$) : Paradoxalement, ce facteur agit en faveur de l'individu (barre rouge), diminuant localement le score de risque.
- **La variable ethnique** ($0.00 < \text{race} \leq 1.00$) : Conformément à l'encodage réalisé (1 pour African-American), on observe que l'origine ethnique contribue positivement au risque de récidive. L'explicabilité locale met ici en lumière une réalité problématique de la boîte noire : le modèle utilise le critère de race comme un facteur de risque intrinsèque.

Test de l'équité algorithmique : Interaction entre passé judiciaire et ethnique

L'une des forces de l'agrégation des explications locales réside dans la capacité à identifier si le modèle traite différemment les individus en fonction de variables sensibles. Pour ce faire, nous avons analysé l'évolution du poids attribué à la variable *priors_count* (nombre d'antécédents) en fonction de l'origine ethnique *race* (Figure A.7).

L'analyse de ce graphique révèle trois phénomènes majeurs concernant la logique interne du modèle *Random Forest* :

1. **La validation de la corrélation criminologique** : On observe une tendance croissante globale. Plus le nombre d'antécédents réels augmente, plus le poids LIME est élevé (passant d'environ -0.25 pour un casier vierge à $+0.35$ pour plus de 10 antécédents). Cela confirme que le modèle a correctement appris que le passé judiciaire est le prédicteur statistique le plus fort de la récidive.
2. **La preuve visuelle du biais racial** : L'observation la plus critique se situe sur le segment $[0, 5]$ antécédents. Pour un même nombre d'infractions (par exemple, $\text{priors_count} = 1$), les points rouges (African-American) se situent quasi-systématiquement au sommet des grappes de points, tandis que les points bleus (Caucasian) occupent le bas.
3. À nombre d'antécédents égal, le modèle semble « sur-pénaliser » le passé judiciaire des populations afro-américaines en lui accordant un poids d'impact supérieur. Cela suggère que la boîte noire ne se contente pas d'ajouter les variables, mais qu'elle crée une synergie où le critère de race amplifie la sévérité du jugement porté sur le casier judiciaire.

Cette visualisation permet de corroborer par l'explicabilité locale les conclusions de l'enquête de *ProPublica* sur le biais systémique de COMPAS. Elle démontre que LIME, par le biais des *dependence plots*, est capable de souligner des disparités de traitement.

c) Application au diagnostic médical : Breast Cancer

L'intégration de l'intelligence artificielle dans le secteur de la santé, notamment pour le dépistage du cancer du sein, impose des exigences de robustesse et de transparence extrêmes. Dans cette section, nous utilisons un modèle *XGBoost* pour classer des tumeurs comme malignes ou bénignes. L'enjeu est ici d'évaluer si les explications fournies par LIME sont suffisamment stables pour être utilisées comme aide à la décision clinique.

Analyse locale et cohérence clinique

Nous avons sélectionné une instance diagnostiquée comme maligne par le modèle. La Figure A.8 décompose les facteurs ayant mené à cette prédiction.

Les variables morphologiques telles que *worst concave points* et *mean concave points* apparaissent comme les principaux contributeurs à la classe « Maligne ». Cette observation est cliniquement cohérente, car les irrégularités de forme des noyaux cellulaires sont des marqueurs classiques de malignité en oncologie.

II.2 Limites de LIME

a) *Instabilité*

Si LIME permet de détecter des biais, l'algorithme souffre d'une limite fondamentale : son **instabilité**. Comme la méthode repose sur un échantillonnage aléatoire autour de l'instance, les explications peuvent varier d'une exécution à l'autre pour un même individu.

Pour mesurer ce phénomène, nous avons généré cinq explications successives avec un nombre d'échantillons restreint ($n = 300$) pour le jeu de données **COMPAS**. La Figure A.9 présente la variance des poids obtenus.

L'observation des boîtes à moustaches confirme une fragilité méthodologique :

1. **Forte volatilité des variables clés** : La variable *priors_count*, bien que dominante, présente une variance élevée. Un utilisateur pourrait donc recevoir des explications d'intensités différentes selon le moment du calcul.
2. **Inversion de polarité** : Pour des variables comme *juv_other_count*, on remarque que la boîte traverse la ligne du zéro. Cela signifie que selon le tirage aléatoire, LIME peut considérer un facteur comme "aggravant" ou "atténuant" pour une même situation.

Cette instabilité pose un problème de confiance majeur pour un expert métier (juge ou conseiller d'insertion). Elle démontre que la qualité de l'explication locale est fortement dépendante du paramétrage de l'échantillonnage et que, sans une rigueur statistique accrue, LIME peut fournir des justifications subjectives plutôt que des vérités mathématiques stables.

b) *Sensibilité au voisinage (Kernel Width)*

Le cœur de notre analyse critique repose sur la stabilité du modèle de substitution local. L'algorithme LIME repose sur un paramètre crucial : le *kernel_width*, qui définit la taille de la zone d'échantillonnage autour de l'individu étudié. La Figure A.10 illustre l'impact de ce paramètre sur l'explication générée pour une même patiente du dataset **Breast Cancer**.

L'observation de ces graphiques révèle une fragilité méthodologique :

- **Voisinage étroit (Kernel = 1.5)** : LIME se focalise sur des micro-variations locales. L'explication est très sensible au bruit et peut accorder une importance disproportionnée à certaines variables.
- **Voisinage global (Kernel = 15.0)** : LIME tend à lisser la frontière de décision. L'explication se rapproche d'une tendance globale du modèle, perdant ainsi sa spécificité locale.

Pour un médecin, cette subjectivité est problématique : selon le réglage choisi par le data scientist, l'argumentaire justifiant un diagnostic peut changer. Cette instabilité souligne que LIME ne fournit pas « la » vérité du modèle, mais une approximation dont la fiabilité dépend entièrement d'un paramétrage arbitraire du voisinage.

II.3 Expérimentations avec SHAP

Pour illustrer les capacités de la bibliothèque **SHAP** et de l'algorithme *TreeExplainer*, nous avons appliqué cette méthode aux trois jeux de données précédemment étudiés avec LIME. Cette approche permet non seulement de valider l'interprétabilité des modèles (Random Forest et XGBoost).

a) *Le cas du Titanic*

Le jeu de données *Titanic* sert ici de point de référence pour vérifier la cohérence des explications SHAP par rapport à des faits historiques connus.

Analyse globale des classes

L'analyse globale (Figure A.11) confirme l'impact déterminant du statut socio-économique. On observe que l'appartenance à la première classe (*Pclass_1*) exerce une influence positive majeure sur la survie. À l'inverse, la troisième classe (*Pclass_3*) pèse lourdement en faveur de la non-survie, ce qui s'explique par la localisation des cabines dans les ponts inférieurs, rendant l'évacuation plus difficile.

Analyse locale d'une prédiction

Pour l'analyse locale, nous avons sélectionné une passagère pour laquelle le modèle prédit la classe 0 (non-survie). La Figure A.12 montre la décomposition de cette probabilité.

Ici, bien que la variable *Sex=1* (femme) pousse la prédiction vers la survie, cet effet est surpassé par l'accumulation de facteurs défavorables : le fait d'appartenir à la classe 3, le prix modeste du billet (*Fare=25.467*) et la présence de 3 membres de la famille à bord (*SibSp=3*). Le modèle décompose ainsi précisément comment ces caractéristiques s'additionnent pour aboutir à la décision finale.

b) *Le cas COMPAS*

L'application de SHAP au jeu de données *COMPAS* permet d'auditer les biais algorithmiques dans un contexte juridique.

Hiérarchisation des risques

Le *Summary Plot* (Figure A.13) révèle que les variables les plus influentes pour prédire la récidive sont le nombre d'antécédents (*priors_count*) et l'âge. Plus le casier judiciaire est chargé et plus l'individu est jeune, plus la valeur de Shapley augmente, poussant le modèle vers une prédiction de récidive élevée. Cela souligne les enjeux éthiques soulevés dans notre introduction : le modèle semble automatiser des préjugés culturels.

Recherche d'interactions

À l'aide d'un *Dependence Plot*, nous avons cherché si l'âge interagissait spécifiquement avec le nombre d'antécédents (Figure A.14). Contrairement à d'autres variables, on n'observe aucune structure claire d'interaction : les différentes valeurs de *priors_count* sont distribuées de manière homogène sur toutes les tranches d'âge. Le modèle traite donc ces deux facteurs de manière indépendante.

c) *Application au diagnostic médical : Breast Cancer*

Sur ce jeu de données à haute dimensionnalité, SHAP devient un outil de sélection de variables critiques pour le diagnostic.

Sélection des biomarqueurs les plus influents

Le graphique en barres (Figure A.15) permet d'isoler immédiatement les caractéristiques les plus déterminantes pour la détection de tumeurs malignes : *worst concave points*, *worst area* et *mean concave points*. Cette synthèse est cruciale en milieu médical pour réduire la complexité de l'analyse sans perdre en précision.

Effet d'interaction biologique

L'analyse de dépendance (Figure A.16) met en lumière une interaction forte entre *worst concave points* et *worst area*. On distingue deux groupes biologiques nets : un groupe où les deux valeurs sont faibles et un groupe où les deux valeurs augmentent de concert, impactant exponentiellement la valeur de Shapley. SHAP capture ici une corrélation morphologique réelle que des méthodes plus simples ne pourraient identifier.

II.4 Synthèse des observations expérimentales

Le tableau ci-dessous résume les principales découvertes effectuées lors de nos tests sur les deux méthodes d'explicabilité.

Dataset	Observations avec LIME	Observations avec SHAP
Titanic	Identification claire de l'effet "Sexe" et "Classe". Forte sensibilité au voisinage pour les passagers atypiques.	Décomposition additive exacte. Le <i>Force Plot</i> permet de voir l'équilibre entre les forces de survie (Sexe) et de décès (Classe 3).
COMPAS	Révèle l'impact du casier judiciaire. Instabilité des poids lors de répétitions sans graine aléatoire fixe (<i>random seed</i>).	Hiérarchie stable. Le <i>Dependence Plot</i> confirme l'absence d'interaction complexe entre l'âge et les antécédents.
Breast Cancer	Modèle de substitution efficace mais difficulté à capturer les interactions entre les biomarqueurs.	Identification de corrélations biologiques (<i>worst area</i> / <i>concave points</i>) grâce aux interactions TreeSHAP.

TABLE II.1 – Récapitulatif des résultats expérimentaux par jeu de données.

LIME vs SHAP

La mise en œuvre pratique de l’explicabilité, détaillée dans la partie précédente à travers l’étude de cas sur *Titanic*, *COMPAS* et *Breast Cancer*, nous a permis d’observer de manière isolée les comportements de LIME et de SHAP.

L’objectif de cette troisième partie est de confronter directement ces deux méthodes. Il ne s’agit plus seulement de décrire leur fonctionnement, mais d’évaluer leur robustesse face à un critère fondamental pour l’intelligence artificielle : la fiabilité de l’explication.

III.1 Stabilité et Robustesse

La différence la plus flagrante entre les deux méthodes réside dans leur stabilité stochastique.

a) La fragilité de LIME

Comme démontré dans nos expérimentations (via le script d’évaluation de la variance sur le jeu de données *COMPAS*), LIME souffre d’une forte instabilité. L’algorithme reposant sur une perturbation aléatoire des données autour de l’instance pour créer son voisinage (via le *Kernel Width*), deux exécutions successives pour le même individu peuvent générer des poids différents. Dans des contextes à haut risque (justice pénale, diagnostic médical), cette volatilité est inacceptable car elle rend l’explication subjective.

b) Le déterminisme de SHAP

À l’inverse, SHAP (et plus particulièrement *TreeSHAP* utilisé dans nos tests) s’appuie sur le calcul exact des valeurs de Shapley. En parcourant exhaustivement les chemins de l’arbre de décision, *TreeSHAP* ne laisse aucune place au hasard. Pour un modèle donné et une instance donnée, l’explication SHAP sera toujours rigoureusement identique. Cette reproductibilité absolue offre une garantie de confiance essentielle pour l’utilisateur final.

III.2 Propriétés des méthodes

Si LIME est intuitif, il s’agit d’une approche plus simpliste. SHAP, en revanche, tire sa force de la théorie des jeux et garantit des propriétés mathématiques que LIME ne possède pas.

- **Propriété de Cohérence (Consistency)** : C’est la limite théorique majeure de LIME. Si l’on modifie le modèle d’apprentissage pour qu’il s’appuie davantage sur une variable spécifique, l’importance locale attribuée par LIME à cette variable peut paradoxalement

diminuer (en raison de la qualité de l'approximation linéaire locale). SHAP garantit mathématiquement le contraire : une contribution accrue dans le modèle se traduira toujours par une valeur de Shapley supérieure ou égale.

- **Propriété d'Additivité (Local Accuracy)** : SHAP garantit que la somme des valeurs de Shapley de chaque variable (plus la valeur de base) est exactement égale à la prédiction finale du modèle. LIME ne fait qu'approximer cette prédiction via son modèle de substitution, laissant souvent un résidu d'erreur inexpliqué.

III.3 Du Local au Global

L'étendue de l'explication offerte par les deux outils constitue un autre point de divergence critique.

a) *LIME : Une vision strictement locale*

LIME est conçu pour expliquer une prédiction unique à la fois. Bien qu'il soit possible d'agréger ces explications locales (comme nous l'avons fait avec nos matrices de corrélation *Valeurs-Poids*), cette agrégation reste un "bricolage" statistique. Le modèle de substitution linéaire global de LIME (SP-LIME) peine à fournir une vision d'ensemble cohérente, surtout face à des modèles hautement non-linéaires.

b) *SHAP : L'unification Local-Global*

SHAP a une capacité à offrir une transition fluide entre l'analyse locale et globale. Les valeurs de Shapley étant additives, la moyenne des valeurs absolues de Shapley sur l'ensemble du jeu de données donne une mesure exacte et mathématiquement fondée de l'importance globale des variables (Feature Importance). Les *Summary Plots* de SHAP permettent d'observer d'un seul coup d'œil l'impact global d'une variable et sa distribution locale, ce que LIME ne peut pas produire.

III.4 Compromis entre les deux méthodes

Malgré ses défauts théoriques, LIME conserve un avantage pratique indéniable face à la méthode SHAP générale (*KernelSHAP*).

Critère	LIME	SHAP (KernelSHAP / TreeSHAP)
Agnosticisme	Total. Fonctionne sur tout type de modèle (Texte, Image, Tabulaire) avec une grande facilité.	KernelSHAP est agnostique mais inutilisable en pratique (trop lent). TreeSHAP est ultra-rapide mais restreint aux arbres.
Temps de calcul	Faible à Modéré (dépendant du nombre d'échantillons).	Exponentiel (KernelSHAP) / Polynomial très rapide (TreeSHAP).
Fidélité	Approximative (dépend du <i>kernel width</i>).	Exacte pour TreeSHAP et très fiable pour KernelSHAP.

TABLE III.1 – Tableau de synthèse des compromis techniques entre LIME et SHAP.

En définitive, le choix entre LIME et SHAP s'apparente à un compromis entre **flexibilité computationnelle** et **rigueur mathématique**. LIME reste un excellent outil d'exploration rapide et visuelle lors de la phase de développement d'un modèle. Cependant, dès lors que l'intelligence artificielle est déployée dans un environnement critique nécessitant des audits, de la certification ou de la redevabilité (comme le prévoit l'IA Act européen), SHAP s'impose comme la seule méthode capable de fournir des garanties théoriques et une reproductibilité suffisantes.

Conclusion Générale

Ce Travail d'Étude et de Recherche avait pour ambition de mieux comprendre le concept de « boîte noire » en apprentissage automatique, en confrontant les bases théoriques de l'Intelligence Artificielle Explicable (XAI) à la réalité pratique de jeux de données complexes.

À travers l'étude de modèles prédictifs appliqués à la survie historique (*Titanic*), à la justice pénale (*COMPAS*) et au diagnostic médical (*Breast Cancer*), nous avons pu évaluer et comparer les deux méthodes phares du domaine : LIME et SHAP.

Notre analyse démontre que l'explicabilité n'est pas une solution unique, mais un spectre de compromis. LIME s'est révélé être un outil d'exploration particulièrement intuitif et agile, idéal pour auditer rapidement des modèles de toute nature. Cependant, son instabilité stochastique et sa sensibilité au paramétrage du voisinage limitent sa pertinence dans des environnements décisionnels critiques. À l'inverse, SHAP apporte la rigueur mathématique qui fait défaut à LIME. En s'appuyant sur la théorie des jeux coopératifs, et grâce à des optimisations algorithmiques majeures comme *TreeSHAP*, cette méthode garantit une cohérence et une fidélité qui imposent aujourd'hui SHAP comme le standard de fiabilité en XAI.

Le piège de l'interprétation

Toutefois, ce travail nous a également permis de mettre en lumière une limite fondamentale, d'ordre éthique. Comme nous l'avons observé lors de notre analyse du jeu de données *COMPAS*, un outil d'explicabilité se contente de refléter la logique interne du modèle, sans jamais juger de sa moralité.

Il existe un risque majeur de « *fairness washing* » (ou cautionnement éthique) : l'utilisateur pourrait être tenté de croire qu'un algorithme est juste simplement parce que ses décisions sont mathématiquement explicables. Or, si les données d'entraînement contiennent des biais systémiques, SHAP calculera avec une exactitude parfaite l'impact d'une variable discriminatoire (comme l'origine ethnique). L'explicabilité n'est donc pas une garantie d'équité, mais un instrument de diagnostic. Elle ne remplace pas la nécessité d'un audit critique des données et de l'intervention humaine dans la boucle décisionnelle.

Vers l'explicabilité profonde

Le domaine de la XAI est en perpétuelle évolution pour s'adapter à la complexité croissante des architectures d'apprentissage. Si notre étude s'est concentrée sur les données tabulaires et les modèles basés sur les arbres (Random Forest, XGBoost), les recherches actuelles se tournent massivement vers le *Deep Learning*.

Les réseaux de neurones profonds, utilisés en vision par ordinateur ou en traitement du langage naturel (LLMs), posent des défis d'interprétabilité d'une toute autre dimension. Pour y répondre, les méthodes étudiées continuent de se développer : on observe l'émergence d'algo-

rithmes comme *DeepSHAP* (une adaptation de SHAP pour les réseaux de neurones connectée à l'algorithme DeepLIFT) ou des approches basées sur les gradients.

En définitive, l'explicabilité de l'IA n'est plus aujourd'hui une simple option technique, mais une exigence sociétale, juridique et scientifique. Ce projet nous aura prouvé que rendre une intelligence artificielle transparente est une étape indispensable pour passer d'une technologie subie à une technologie de confiance.

Annexes : Figures et Illustrations




FIGURE A.1 – Décomposition SHAP d’une prédiction de prix. Le modèle part de la valeur moyenne ($E[f(z)] = 1.904$) et ajuste ce score selon les contributions locales (valeurs de Shapley) pour atteindre la prédiction finale ($f(x) = 1.681$).

Algorithm 1 Estimating $E[f(x) | x_S]$

```

1: procedure EXPVALUE( $x, S, tree = \{v, a, b, t, r, d\}$ )
2:   procedure G( $j$ ) ▷ Define the G procedure which we will call on line 10
3:     if  $v_j \neq \text{internal}$  then ▷ Check if node  $j$  is a leaf
4:       return  $v_j$  ▷ Return the leaf's value
5:     else
6:       if  $d_j \in S$  then ▷ Check if we are conditioning on this feature
7:         return  $G(a_j)$  if  $x_{d_j} \leq t_j$  else  $G(b_j)$  ▷ Use the child on the decision path
8:       else
9:         return  $[G(a_j) \cdot r_{a_j} + G(b_j) \cdot r_{b_j}] / r_j$  ▷ Weight children by their coverage
10:  return  $G(1)$  ▷ Start at the root node

```

FIGURE A.2 – Représentation de l’algorithme récursif TreeSHAP.




FIGURE A.3 – Explication locale LIME pour un passager du Titanic (Probabilité de survie : 0.12). Les barres rouges indiquent les facteurs diminuant les chances de survie, les barres vertes ceux les augmentant.




FIGURE A.4 – Matrice de corrélation croisée entre les valeurs des variables et leurs poids LIME respectifs. Les coefficients proches de ± 1 sur la diagonale indiquent une règle de décision stable.




FIGURE A.5 – Graphe d'interaction LIME : Évolution du poids de la classe sociale selon le sexe. Les points bleus représentent les femmes (0) et les rouges les hommes (1).




FIGURE A.6 – Explication locale LIME pour un profil COMPAS (Probabilité : 0.64). Le poids vert indique un facteur augmentant le risque de récidive selon le modèle.




FIGURE A.7 – Graphe d'interaction LIME : Influence de l'ethnie sur l'importance du casier judiciaire. Les points rouges représentent les individus afro-américains et les bleus les individus caucasiens.




FIGURE A.8 – Explication locale LIME pour un cas de tumeur maligne (Indice de confiance : 1.00). La présence de points concaves et la surface élevée dominent la décision.




FIGURE A.9 – Instabilité des poids LIME sur 5 exécutions pour un même profil. La largeur des boîtes à moustaches illustre l'incertitude du modèle de substitution.




FIGURE A.10 – Instabilité de LIME selon la largeur du noyau. Une variation du voisinage modifie la hiérarchie et l'intensité des poids attribués.




FIGURE A.11 – Impact des classes sociales sur la survie (Modèle Random Forest).




FIGURE A.12 – Explication locale SHAP pour une passagère du Titanic (Non-survie).




FIGURE A.13 – Importance globale des variables pour la prédiction de récidive (XGBoost).




FIGURE A.14 – Analyse de dépendance entre l'âge et les antécédents (Absence d'interaction).




FIGURE A.15 – Hiérarchie des variables pour le diagnostic du cancer (Random Forest).




FIGURE A.16 – Interaction entre la surface et les points concaves (XGBoost).

Fonctionnement des modèles "Boîtes Noires"

Afin de comprendre la nécessité des méthodes d'explicabilité, il semble important de rappeler brièvement comment fonctionnent les modèles non linéaires utilisés dans nos expérimentations. Ces algorithmes reposent fondamentalement sur les arbres de décision CART (*Classification and Regression Trees*).

B.1 Les Arbres CART et les Random Forest

L'algorithme CART est une méthode de construction d'arbres binaires. Il opère par un partitionnement récursif de l'espace des données : à chaque étape, l'algorithme choisit intelligemment une variable pour couper les données en deux sous-groupes. Ce processus est répété jusqu'à atteindre des feuilles (nœuds terminaux). Dans chaque feuille, le modèle effectue une prévision très simple : il assigne la classe majoritaire pour un problème de classification, ou la moyenne des observations pour un problème de régression.

Bien qu'un arbre CART unique soit facilement interprétable, il est sujet au surapprentissage. Pour pallier ce problème, l'algorithme **Random Forest** (Forêt Aléatoire) construit un grand ensemble d'arbres CART indépendants et agrège leurs prédictions. Cette agrégation améliore considérablement les performances prédictives, mais détruit l'interprétabilité directe du modèle, créant ainsi une première forme de "boîte noire".

La Figure B.1 ci-dessous illustre visuellement ce mécanisme : chaque arbre de la forêt est entraîné sur un sous-échantillon des données et émet sa propre prédiction. L'algorithme opère ensuite un vote majoritaire (ou calcule la moyenne) pour délivrer la prédiction finale.




FIGURE B.1 – Schéma de principe du fonctionnement d'une Forêt Aléatoire (*Random Forest*).[Gee25]

B.2 XGBoost (Extreme Gradient Boosting)

Le modèle XGBoost offre généralement de meilleures performances empiriques que les Random Forests, à condition de procéder à un réglage minutieux de ses hyperparamètres. Contrairement à la forêt aléatoire qui construit ses arbres de manière indépendante, le Gradient Boosting est un modèle additif qui s'améliore au cours du temps en apprenant de ses erreurs.

Mathématiquement, à l'itération $t + 1$, le modèle met à jour sa fonction de prédiction $\hat{f}$ en ajoutant un nouvel arbre correcteur $\hat{g}_{t+1}$:

$$\hat{f}_{t+1}(\vec{x}) = \hat{f}_t(\vec{x}) + \eta_t \hat{g}_{t+1}(\vec{x})$$

- L'arbre correcteur $\hat{g}_{t+1}$ est généralement un arbre CART peu profond.
- Le paramètre η_t représente le taux d'apprentissage (*learning rate*). Il est typiquement très petit (de l'ordre de 10^{-2} voire 10^{-4}) afin d'appliquer des corrections fines et progressives.

L'algorithme calcule les résidus (l'écart entre la vraie valeur et la prédiction actuelle) et entraîne l'arbre correcteur pour prédire ces erreurs. Bien que très puissant, XGBoost nécessite de calibrer rigoureusement la profondeur des arbres, le nombre d'itérations et le taux d'apprentissage pour éviter un phénomène de surapprentissage sévère.

Références bibliographiques

- [Gee25] GeeksforGeeks. Random forest algorithm in machine learning, 2025. Consulté le 31 mars 2026.
- [LEC⁺19] Scott M Lundberg, Gabriel Erion, Hugh Chen, Alex DeGrave, Jordan M Prutkin, Bala Nair, Ronit Katz, Jonathan Himmelfarb, Nisha Bansal, and Su-In Lee. Explainable ai for trees : From local explanations to global understanding. *arXiv preprint arXiv :1905.04610*, 2019.
- [LL17] Scott M Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems (NIPS)*, volume 30. 2017.
- [RSG16] Marco Tulio Ribeiro, Sameer Singh, and Carlos Guestrin. "why should i trust you ?" : Explaining the predictions of any classifier. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 1135–1144. ACM, 2016.
- Molnar, C. (2025). Interpretable Machine Learning : A Guide for Making Black Box Models Explainable (3rd ed.). christophm.github.io/interpretable-ml-book/